

Recuperación multisalto sobre un grafo de aserciones reificadas con memoria canónica de entidades y planificación de la evidencia

Evaluación en benchmarks públicos y aplicación al asistente clínico sobre las guías de
GeSIDA

Septiembre de 2026

Guion

Introducción


Metodología

Resultados

Discusión

Aplicación: asistente clínico sobre las guías de GeSIDA

El problema: la pregunta no se parece a la evidencia que falta




- La recuperación densa/léxica encuentra lo *nombrado*, no lo *encadenado*: la información que identifica al pasaje puente solo aparece *tras leer* el primero.
- Consecuencia medible: exhaustividad parcial alta con **cadena rota** (BM25 en cadenas dobles: $R@5 = 50,9$ pero $FC@5 = 0,9$).

La métrica alineada con la tarea: cadena completa (FC@k)

Definiciones (pregunta q , oro G_q , top- k T_k)

$$R@k = \frac{|G_q \cap T_k|}{|G_q|} \quad FC@k = \mathbf{1}[G_q \subseteq T_k]$$




3 de 4 pasajes $\Rightarrow$ R@5 alta,
FC@5 = 0: **no hay respuesta fundamentada**

- Un lector no puede componer la respuesta si le falta *un* eslabón: R@5 = 0,75 en una cadena de 4 vale lo mismo que 0.
- FC@k (*Full Chain Retrieval*) es la métrica de integridad del razonamiento propuesta por CatRAG (Lau et al., ACL 2026).


Estado del arte: HippoRAG 2 (PPR sobre grafo de triplete; Gutiérrez et al. 2025) y CatRAG (recorrido adaptativo a la consulta). Sus dos límites estructurales: *identidad de entidades sin resolver* y *recursos fijos por consulta*.

Arquitectura: pagar una vez en indexación, decidir bien en consulta

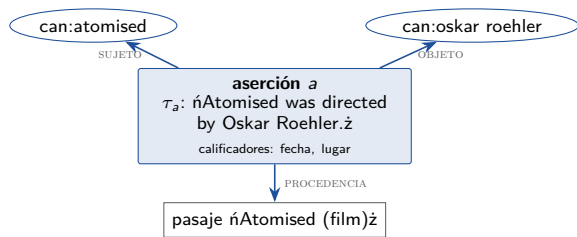


- Modelos pequeños en todo: gpt-4o-mini / deepseek-chat + text-embedding-3-small (1536 d).
- En **naranja**, las tres decisiones LLM de la consulta (el *planificador*); el resto es álgebra y estructura.

Pieza 1 ð La unidad semántica: aserción reificada, no triplete



(a) HippoRAG 2: el hecho es una *arista* binaria, anónima, sin procedencia



(b) CatRAG-Reif: el hecho es un *nodo* con frase propia, roles *n*-arios y vector $e(\tau_a)$

- Se incrusta **la frase**, no la etiqueta: robusto a etiquetas ruidosas; las fechas viajan *dentro* del hecho.
- El paseo aleatorio **razona a través del hecho** (entidad $\rightarrow$ aserción $\rightarrow$ otra entidad / pasaje) y su tránsito se modula por la consulta: $\mu_a = \frac{1}{4} + \frac{3}{4} \tilde{\sigma}_a$.

Pieza 2 ù Memoria canónica de entidades: matar las ñislasž en el índice



entrada canónica can:h. p. lovecraft
alias: {H. P. Lovecraft; Howard Phillips Lovecraft}
descripción: ñAmerican writer of weird fiction...ž
pasaje propio: *H. P. Lovecraft*

fichas por mención (nombre + contexto) → candidatos por 2 canales → restricciones duras (fechas, ordinales) → adjudicación LLM → fusión; el título del artículo es alias del sujeto

- Construida **una vez, solo del corpus** (jamás del oro); auditable; con QIDs de Wikidata como verificación externa opcional (v4).
- Resultado: variantes de nombre colapsan en **un** nodo ⇒ el grafo canónico no necesita aristas de sinonimia; 178/188 islas resueltas en el sondeo.
- Es el análogo, derivado del corpus, del *linker* SNOMED del caso clínico.

Pieza 3 ũ El analista: planificar la cadena antes de seleccionar

ńWhich film has the director died first, Bílá Spona or A Night at Earl Carroll's?ž

hechos candidatos (top-40 coseno ũ frontera)
2: A Night at Earl Carroll's ... **directed by Kurt Neumann**
6: Bílá spona was ... **directed by Martin Frič**
8: *Earl Carroll* (el actor) *died on June 17, 1948* ...

plan (huecos):

director de Bílá spona → Martin Frič

fecha de muerte de Martin Frič

director de A Night... → Kurt Neumann

fecha de muerte de Kurt Neumann

Sin plan (selector directo, tope 4):

eligió al actor Earl Carroll como řdirectorž

y omitió a Kurt Neumann *que estaba en la lista* ⇒ cadena rota.

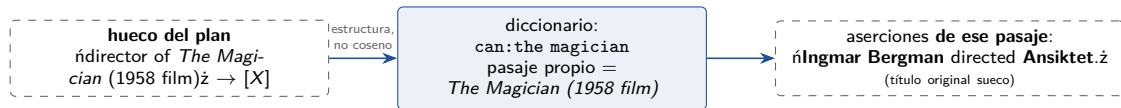
Con plan (tope = n.ž de huecos):

selecciona los dos hechos puente; regla dura:

prohibido rellenar huecos con conocimiento propio del modelo ([X]).

La misma llamada hace de **enlazador** (menciones → forma canónica → diccionario) y declara los **huecos sin cubrir**, que alimentan el salto dirigido y, en clínica, la abstención fundamentada.

Pieza 4 ù Salto dirigido estructural: cuando el artículo habla en otro idioma



el coseno del hueco con ningmar Bergman directed Ansiktetž es **bajo** (cero vocabulario común);
la ruta **estructural** (entidad enlazada → su pasaje propio → sus hechos, con procedencia visible)
lo rescata: el mini-filtro aprueba, Bergman se siembra, su biografía entra en el top-2

- Solo se ejecuta si el plan dejó huecos (~15–25 % de las consultas); una ronda.
- Es la capacidad nueva de verdad: resolver puentes **inmunes al alias** (idiomas, títulos originales), imposibles para similitud y sinonimia.

Piezas 5–6 ù Siembra con compuerta dura y PPR modulado; conjunto final


Vector de reinicio $\mathbf{v}$ (4 fuentes):

1. **compuerta dura**: solo siembran las entidades de hechos *aprobados* (peso 1); si nada aprueba $\rightarrow$ degradación suave al denso;
2. presa densa sobre *todos* los pasajes ($\times 0,05$);
3. anclas débiles ($\epsilon = 0,05$);
4. **pasaje propio**: $\mathbf{v}(\pi(\varepsilon)) \mathrel{+}= 0,5 \mathbf{v}(\varepsilon)$ — *ñel artículo de una entidad es la entidadz.*

$$\mathbf{p}^{(t+1)} = \lambda \left(P^\top \mathbf{p}^{(t)} + m_{\text{colg}} \mathbf{v} \right) + (1 - \lambda) \mathbf{v}, \quad \lambda = 0,5$$

con P renormalizada tras modular las entradas a cada hecho por su afinidad ($\mu_a \in [\frac{1}{4}, 1]$; los aprobados a peso completo).


Conjunto final (salvo comparaciones simples):



FC@ k es una propiedad *del conjunto*, no de cada pasaje: esta decisión no la puede expresar un ranking punto a punto. Aporta +6 puntos de FC@2 (orden temprano).

Protocolo experimental: paridad estricta y separación de datos


- **Datasets** (subconjuntos de reproducción de HippoRAG 2/CatRAG): 2WikiMultihopQA (1000 preguntas $\times$ 6119 pasajes) y HotpotQA (1000 $\times$ 9811); recuperación *abierta* contra el corpus completo.
- **Paridad**: HippoRAG 2 ejecutado con *su propio código* y los *mismos modelos*; CatRAG publica con este mismo backbone (gpt-4o-mini+te3-small) $\Rightarrow$ comparación directa legítima.
- **Validación cruzada de la reproducción**: nuestro HippoRAG 2 en 2Wiki (85,9/65,8) coincide **al decimal** con la reproducción independiente del artículo de CatRAG (85,9/66,1).
- **Estadística**: pareado por pregunta, bootstrap $B=2000$, IC 95 %.



Configuración **congelada** antes de medir; en HotpotQA, *cero ajuste* al conjunto.


2WikiMultihopQA: resultado principal (todos con el mismo backbone)

	R@2	R@5	FC@5	FC@10
BM25	—	65,8	32,8	40,1
HippoRAG 2 (su código)	70,7	85,9	65,8	71,7
CatRAG (publicado; código no liberado)	—	87,0	67,6	—
CATRAG-REIF v3 (diccionario)	73,0	96,0	90,6	93,4
CatRAG-Reif v4 + planificador (gpt-4o-mini)	80,2	98,1	96,0	96,7
CatRAG-Reif v4 + planificador (deepseek-chat)	84,2	98,9	97,7	97,8



Pareado v4–HippoRAG 2: $\Delta FC@5 = +31,9$ [+28,9, +34,9] (gana 326 / pierde 7); todos los tipos significativos. El artículo de HippoRAG 2 con NV-Embed-v2 (7 B, GPU) reporta $R@5 = 90,4$; aquí 98,9 con modelos de una fracción de ese coste.

El hallazgo central: acumulación frente a colapso con la profundidad



Modelo nulo: eslabones independientes


$$\Rightarrow FC \approx p^{|G_q|}$$

	C predicho	C obs.	razón
HippoRAG 2	59,2	12,3	0,21
CATRAG-REIF	80,3	83,8	1,04

CATRAG-REIF degrada por *acumulación* de $\sim 5\%$ de error por eslabón. HippoRAG 2 *colapsa*: sus recursos por consulta (selección ≤ 4 , masa, holgura del top-5) son fijos y compartidos entre las dos cadenas. El planificador invierte el gradiente: con v4, la cadena doble alcanza $FC@5 = 98,7$ — el segmento históricamente peor pasa a ser el mejor.

Atribución: ablaciones y control sin grafo

Escalera de contribuciones (sondeo):



El plan por sí solo apenas mueve (+0,5): su valor es *habilitar* al salto (+3,0; cadena doble 86 → 96) y al conjunto (+1,5; +6 FC@2).

¿Grafo o planificador? Control *sin grafo* con idéntico presupuesto LLM (mismo analista/salto/conjunto sobre top-20 denso):

banco	v4	control	Δ [IC 95 %]
2Wiki	96,0	83,3	+12,7 [+10,5, +14,9]
HotpotQA	90,2	83,9	+6,3 [+4,1, +8,6]

Criterio pre-registrado (≥ 5 y sig. en ambos): **cumplido**
⇒ la **representación** aporta más allá del planificador. El planificador solo repara cadenas dobles; el puente simple lo repara el grafo (oro perdido por el control: 130/141 ni siquiera en su top-20).

Generalización sin ajuste y robustez al modelo

HotpotQA ($1\,000 \times 9\,811$), configuración congelada de 2Wiki:

	R@5	FC@5
BM25 (nuestro)	72,8	49,5
denso te3-small (pub.)	81,3	64,9
HippoRAG 2 (publicado)	87,1	75,5
CatRAG (publicado)	89,5	80,4
CatRAG-Reif v4 (4o-mini)	94,7	90,2
CatRAG-Reif v4 (deepseek)	96,0	93,0

+6,5 R@5 / +12,6 FC@5 sobre CatRAG con *cero* ajuste al conjunto.

El modelo del planificador es intercambiable (sondeo 2Wiki, FC@5):

modelo	FC@5	\$/consulta
deepseek-chat	97,5	0,0010
groq gpt-oss-20b	97,0	0,0005
gpt-4o	96,5	0,012
gpt-4o-mini	96,0	0,0008

La ganancia es del *diseño de la tarea*, no del tamaño: un 20 B abierto casi empata con gpt-4o a 1/24 del coste. Estudio completo: ~40 \$; toda llamada cacheada (reproducción a coste cero).

Discusión: por qué funciona y qué falta

Tres principios, cada uno elimina una dependencia de la profundidad:

1. **Identidad en el índice** (memoria canónica): las *nislasz* no se multiplican con los saltos; la sinonimia por umbral sí.
2. **Hechos como nodos de primera clase**: la masa viaja *a través* del hecho aprobado; los calificadores viajan con él.
3. **Recursos que escalan con la cadena** (plan, salto, conjunto): el presupuesto se asigna por hueco, no por consulta — de ahí la inversión del gradiente en cadenas dobles.

Validez: reproducción del baseline verificada al decimal contra una reproducción independiente; diseño íntegro en conjuntos retenidos; una medición por configuración; artefactos y cachés públicos (reproducible a coste cero).

Límites y trabajo en curso: QA extremo a extremo (EM/F1, JSR) pendiente; MuSiQue (saltos 2/3/4 etiquetados: contraste directo del modelo multiplicativo); inferencia con $n=108$ no alcanza significación aislada; heurísticas léxicas residuales sustituidas por el analista, pendiente de medir en otros idiomas.

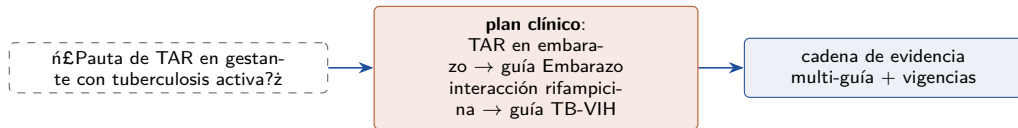
El caso de uso origen: asistente sobre 8 guías clínicas de GeSIDA

La arquitectura no nació en Wikipedia: es la generalización del asistente clínico VIH **ya construido**, donde cada pieza tiene su análogo curado:

benchmark	clínica (GeSIDA)
memoria canónica del corpus aserciones reificadas	SNOMED CT/UMLS (SCTID) aserciones con deóntica , grado de evidencia y vigencia
enrutador de intención	router clínico (paciente, numérica) + lente de umbrales
pasaje propio	sección normativa de la guía

Estado actual (producción, congelada):

- 8 guías; banco de 505 preguntas con validación clínica en curso;
- preguntas multi-guía (nivel 4): 84,9 % en el top-20 en modo grafo (denso: 24,7; BM25: 45,2) — el análogo clínico del multisalto;
- curación con humano en el bucle: bandeja de anclajes SNOMED auditable.



Qué aporta esta investigación a la clínica, y con qué salvaguardas

Los tres portes con evidencia detrás:

1. **Cadena de evidencia multi-guía:** las preguntas nivel 4 son el análogo del puente; el gradiente invertido predice la mayor ganancia ahí.
2. **Abstención fundamentada:** los *huecos sin cubrir* del plan se convierten en *¿no hay evidencia sobre X en las guías?* — el fallo silencioso ($FC = 0$ respondido de memoria) pasa a ser un aviso explícito y medible por pregunta.
3. **JSR clínico:** éxito = cadena normativa completa y respuesta correcta y vigencia comprobada — respuesta con expediente.

Salvaguardas no negociables:

- Datos clínicos **nunca** a proveedores sin garantías (DeepSeek excluido del caso clínico); el diseño es agnóstico al modelo $\Rightarrow$ proveedor UE o modelo local;
- validación *offline* contra el banco de 505 antes de tocar producción (sistema actual congelado y etiquetado);
- terminología curada (SNOMED) como fuente de verdad de identidad; el LLM propone, **nunca decide identidades**;
- trazabilidad completa: cada respuesta con su cadena, procedencia y vigencia.

Conclusiones

1. Un grafo de **aserciones reificadas** sobre **entidades canónicas**, consultado con un **planificador de la evidencia**, recupera la cadena completa donde el estado del arte la rompe: 2Wiki FC@5 **97,7** frente a 65,8 (HippoRAG 2) y 67,6 (CatRAG), mismo backbone; HotpotQA **93,0** frente a 80,4 con cero ajuste.
2. La mejora está *atribuida*: representación (+12,7/+6,3 FC@5 frente al control sin grafo con idéntico presupuesto LLM) + planificador (repara las cadenas dobles: gradiente invertido) — y es *acumulación*, no colapso ($FC \approx p^{|G_q|}$).
3. Todo con modelos pequeños e intercambiables ($\sim 0,001$ \$/consulta), reproducible a coste cero, y con un camino directo a la clínica: mismas piezas con terminología curada, y la abstención fundamentada como dividendo de seguridad.

Gracias — preguntas.

código y artefactos: github.com/bjur27r/hiv_rag (rama eval-wiki2)