

# Recuperación multisalto sobre un grafo de aserciones reificadas con memoria canónica de entidades y planificación de la evidencia

Evaluación en benchmarks públicos y aplicación al asistente clínico sobre las guías de  
GeSIDA

Septiembre de 2026

# Guion

Introducción


Metodología

Resultados

Discusión

Aplicación: asistente clínico sobre las guías de GeSIDA

## El problema: la pregunta no se parece a la evidencia que falta



- La recuperación densa/léxica encuentra lo *nombrado*, no lo *encadenado*: la información que identifica al pasaje puente solo aparece *tras leer* el primero.
- Consecuencia medible: exhaustividad parcial alta con **cadena rota** (BM25 en cadenas dobles:  $R@5 = 50,9$  pero  $FC@5 = 0,9$ ).

# La métrica alineada con la tarea: cadena completa (FC@k)

Definiciones (pregunta  $q$ , oro  $G_q$ , top- $k$   $T_k$ )

$$R@k = \frac{|G_q \cap T_k|}{|G_q|} \quad FC@k = \mathbf{1}[G_q \subseteq T_k]$$

film A → director A


film B → ¿director B?

3 de 4 pasajes  $\Rightarrow$  R@5 alta,  
FC@5 = 0: **no hay respuesta fundamentada**

- Un lector no puede componer la respuesta si le falta *un* eslabón: R@5 = 0,75 en una cadena de 4 vale lo mismo que 0.
- FC@k (*Full Chain Retrieval*) es la métrica de integridad del razonamiento propuesta por CatRAG (Lau et al., ACL 2026).


**Estado del arte:** HippoRAG 2 (PPR sobre grafo de triplete; Gutiérrez et al. 2025) y CatRAG (recorrido adaptativo a la consulta). Sus dos límites estructurales: *identidad de entidades sin resolver* y *recursos fijos por consulta*.

# Arquitectura: pagar una vez en indexación, decidir bien en consulta




- Modelos pequeños en todo: gpt-4o-mini / deepseek-chat + text-embedding-3-small (1536 d).
- En **naranja**, las tres decisiones LLM de la consulta (el *planificador*); el resto es álgebra y estructura.

# Pieza 1 ð La unidad semántica: aserción reificada, no triplete




(a) HippoRAG 2: el hecho es una *arista* binaria, anónima, sin procedencia



(b) CatRAG-Reif: el hecho es un *nodo* con frase propia, roles *n*-arios y vector  $e(\tau_a)$

- Se incrusta **la frase**, no la etiqueta: robusto a etiquetas ruidosas; las fechas viajan *dentro* del hecho.
- El paseo aleatorio **razona a través del hecho** (entidad  $\rightarrow$  aserción  $\rightarrow$  otra entidad / pasaje) y su tránsito se modula por la consulta:  $\mu_a = \frac{1}{4} + \frac{3}{4} \tilde{\sigma}_a$ .

## Pieza 2 ù Memoria canónica de entidades: matar las ñislasž en el índice



sinonimia por umbral (HippoRAG 2: 172k aristas):  
falla justo donde más se necesita  
**57 % de los fallos de cadena eran islas**

**entrada canónica** can:h. p. lovecraft  
alias: {H. P. Lovecraft; Howard Phillips Lovecraft}  
descripción: ñAmerican writer of weird fiction...ž  
**pasaje propio:** *H. P. Lovecraft*

fichas por mención (nombre + contexto) → candidatos por 2 canales → restricciones duras (fechas, ordinales) → adjudicación LLM → fusión; el título del artículo es alias del sujeto

- Construida **una vez, solo del corpus** (jamás del oro); auditable; con QIDs de Wikidata como verificación externa opcional (v4).
- Resultado: variantes de nombre colapsan en **un** nodo ⇒ el grafo canónico no necesita aristas de sinonimia; 178/188 islas resueltas en el sondeo.
- Es el análogo, derivado del corpus, del *linker* SNOMED del caso clínico.

## Pieza 3 ù El analista: planificar la cadena antes de seleccionar

ñWhich film has the director died first, Bílá Spona or A Night at Earl Carroll's?ž

hechos candidatos (top-40 coseno  $\cup$  frontera)

2: A Night at Earl Carroll's ... **directed by Kurt Neumann**

6: Bílá spona was ... **directed by Martin Frič**

8: *Earl Carroll* (el actor) *died on June 17, 1948* ...

**plan** (huecos):

director de Bílá spona  $\rightarrow$  Martin Frič

fecha de muerte de Martin Frič

director de A Night...  $\rightarrow$  Kurt Neumann

fecha de muerte de Kurt Neumann

**Sin plan** (selector directo, tope 4):

**eligió al actor Earl Carroll como ñdirectorž**

y omitió a Kurt Neumann *que estaba en la lista*  $\Rightarrow$  cadena rota.

**Con plan** (tope = n.ž de huecos):


**selecciona los dos hechos puente**; regla dura:

prohibido rellenar huecos con conocimiento propio del modelo ([X]).

La misma llamada hace de **enlazador** (menciones  $\rightarrow$  forma canónica  $\rightarrow$  diccionario) y declara los **huecos sin cubrir**, que alimentan el salto dirigido y, en clínica, la abstención fundamentada.



## Pieza 4 ù Salto dirigido estructural: cuando el artículo habla en otro idioma



el coseno del hueco con ñIngmar Bergman directed *Ansiktet*ž es **bajo** (cero vocabulario común);  
la ruta **estructural** (entidad enlazada → su pasaje propio → sus hechos, con procedencia visible)  
lo rescata: el mini-filtro aprueba, Bergman se siembra, su biografía entra en el top-2

- Solo se ejecuta si el plan dejó huecos (~15–25 % de las consultas); una ronda.
- Es la capacidad nueva de verdad: resolver puentes **inmunes al alias** (idiomas, títulos originales), imposibles para similitud y sinonimia.

# Piezas 5–6 ù Siembra con compuerta dura y PPR modulado; conjunto final


## Vector de reinicio $\mathbf{v}$ (4 fuentes):

1. **compuerta dura**: solo siembran las entidades de hechos *aprobados* (peso 1); si nada aprueba  $\rightarrow$  degradación suave al denso;
2. presa densa sobre *todos* los pasajes ( $\times 0,05$ );
3. anclas débiles ( $\epsilon = 0,05$ );
4. **pasaje propio**:  $\mathbf{v}(\pi(\epsilon)) \mathrel{+}= 0,5 \mathbf{v}(\epsilon)$  — *ñel artículo de una entidad es la entidadz.*

$$\mathbf{p}^{(t+1)} = \lambda \left( P^\top \mathbf{p}^{(t)} + m_{\text{colg}} \mathbf{v} \right) + (1 - \lambda) \mathbf{v}, \quad \lambda = 0,5$$

con  $P$  renormalizada tras modular las entradas a cada hecho por su afinidad ( $\mu_a \in [\frac{1}{4}, 1]$ ; los aprobados a peso completo).


## Conjunto final (salvo comparaciones simples):



FC@ $k$  es una propiedad *del conjunto*, no de cada pasaje: esta decisión no la puede expresar un ranking punto a punto. Aporta +6 puntos de FC@2 (orden temprano).

# Protocolo experimental: paridad estricta y separación de datos


- **Datasets** (subconjuntos de reproducción de HippoRAG 2/CatRAG): 2WikiMultihopQA (1000 preguntas  $\times$  6119 pasajes) y HotpotQA (1000  $\times$  9811); recuperación *abierta* contra el corpus completo.
- **Paridad**: HippoRAG 2 ejecutado con *su propio código* y los *mismos modelos*; CatRAG publica con este mismo backbone (gpt-4o-mini+te3-small)  $\Rightarrow$  comparación directa legítima.
- **Validación cruzada de la reproducción**: nuestro HippoRAG 2 en 2Wiki (85,9/65,8) coincide **al decimal** con la reproducción independiente del artículo de CatRAG (85,9/66,1).
- **Estadística**: pareado por pregunta, bootstrap  $B=2000$ , IC 95 %.



Configuración **congelada** antes de medir; en HotpotQA, *cero ajuste* al conjunto.


## 2WikiMultihopQA: resultado principal (todos con el mismo backbone)

|                                                      | R@2         | R@5         | FC@5        | FC@10       |
|------------------------------------------------------|-------------|-------------|-------------|-------------|
| BM25                                                 | —           | 65,8        | 32,8        | 40,1        |
| HippoRAG 2 (su código)                               | 70,7        | 85,9        | 65,8        | 71,7        |
| CatRAG (publicado; código no liberado)               | —           | 87,0        | 67,6        | —           |
| CATRAG-REIF v3 (diccionario)                         | 73,0        | 96,0        | 90,6        | 93,4        |
| <b>CatRAG-Reif v4 + planificador (gpt-4o-mini)</b>   | 80,2        | 98,1        | 96,0        | 96,7        |
| <b>CatRAG-Reif v4 + planificador (deepseek-chat)</b> | <b>84,2</b> | <b>98,9</b> | <b>97,7</b> | <b>97,8</b> |



Pareado v4–HippoRAG 2:  $\Delta FC@5 = +31,9$  [+28,9, +34,9] (gana 326 / pierde 7); todos los tipos significativos. El artículo de HippoRAG 2 con NV-Embed-v2 (7 B, GPU) reporta  $R@5 = 90,4$ ; aquí 98,9 con modelos de una fracción de ese coste.

# El hallazgo central: acumulación frente a colapso con la profundidad



**Modelo nulo:** eslabones independientes


$$\Rightarrow FC \approx p^{|G_q|}$$

|             | C predicho | C obs. | razón |
|-------------|------------|--------|-------|
| HippoRAG 2  | 59,2       | 12,3   | 0,21  |
| CATRAG-REIF | 80,3       | 83,8   | 1,04  |

CATRAG-REIF degrada por *acumulación* de  $\sim 5\%$  de error por eslabón. HippoRAG 2 *colapsa*: sus recursos por consulta (selección  $\leq 4$ , masa, holgura del top-5) son fijos y compartidos entre las dos cadenas. El planificador invierte el gradiente: con v4, la cadena doble alcanza  $FC@5 = 98,7$  — el segmento históricamente peor pasa a ser el mejor.

# Atribución: ablaciones y control sin grafo

## Escalera de contribuciones (sondeo):



El plan por sí solo apenas mueve (+0,5): su valor es *habilitar* al salto (+3,0; cadena doble 86 → 96) y al conjunto (+1,5; +6 FC@2).

**¿Grafo o planificador?** Control *sin grafo* con idéntico presupuesto LLM (mismo analista/salto/conjunto sobre top-20 denso):

| banco    | v4   | control | $\Delta$ [IC 95 %]   |
|----------|------|---------|----------------------|
| 2Wiki    | 96,0 | 83,3    | +12,7 [+10,5, +14,9] |
| HotpotQA | 90,2 | 83,9    | +6,3 [+4,1, +8,6]    |

Criterio pre-registrado ( $\geq 5$  y sig. en ambos): **cumplido**  
⇒ la **representación** aporta más allá del planificador. El planificador solo repara cadenas dobles; el puente simple lo repara el grafo (oro perdido por el control: 130/141 ni siquiera en su top-20).

# Generalización sin ajuste y robustez al modelo

**HotpotQA** ( $1\,000 \times 9\,811$ ), configuración congelada de 2Wiki:

|                                  | R@5         | FC@5        |
|----------------------------------|-------------|-------------|
| BM25 (nuestro)                   | 72,8        | 49,5        |
| denso te3-small (pub.)           | 81,3        | 64,9        |
| HippoRAG 2 (publicado)           | 87,1        | 75,5        |
| CatRAG (publicado)               | 89,5        | 80,4        |
| <b>CatRAG-Reif v4 (4o-mini)</b>  | 94,7        | 90,2        |
| <b>CatRAG-Reif v4 (deepseek)</b> | <b>96,0</b> | <b>93,0</b> |

+6,5 R@5 / +12,6 FC@5 sobre CatRAG con *cero* ajuste al conjunto.

**El modelo del planificador es intercambiable** (sondeo 2Wiki, FC@5):

| modelo           | FC@5 | \$/consulta |
|------------------|------|-------------|
| deepseek-chat    | 97,5 | 0,0010      |
| groq gpt-oss-20b | 97,0 | 0,0005      |
| gpt-4o           | 96,5 | 0,012       |
| gpt-4o-mini      | 96,0 | 0,0008      |

La ganancia es del *diseño de la tarea*, no del tamaño: un 20 B abierto casi empata con gpt-4o a 1/24 del coste. Estudio completo: ~40 \$; toda llamada cacheada (reproducción a coste cero).

# Discusión: por qué funciona y qué falta

**Tres principios, cada uno elimina una dependencia de la profundidad:**

1. **Identidad en el índice** (memoria canónica): las *nislasz* no se multiplican con los saltos; la sinonimia por umbral sí.
2. **Hechos como nodos de primera clase**: la masa viaja *a través* del hecho aprobado; los calificadores viajan con él.
3. **Recursos que escalan con la cadena** (plan, salto, conjunto): el presupuesto se asigna por hueco, no por consulta — de ahí la inversión del gradiente en cadenas dobles.

**Validez**: reproducción del baseline verificada al decimal contra una reproducción independiente; diseño íntegro en conjuntos retenidos; una medición por configuración; artefactos y cachés públicos (reproducible a coste cero).

**Límites y trabajo en curso**: QA extremo a extremo (EM/F1, JSR) pendiente; MuSiQue (saltos 2/3/4 etiquetados: contraste directo del modelo multiplicativo); inferencia con  $n=108$  no alcanza significación aislada; heurísticas léxicas residuales sustituidas por el analista, pendiente de medir en otros idiomas.




# El caso de uso origen: asistente sobre 8 guías clínicas de GeSIDA

La arquitectura no nació en Wikipedia: es la generalización del asistente clínico VIH **ya construido**, donde cada pieza tiene su análogo curado:


| benchmark                                            | clínica (GeSIDA)                                                                                          |
|------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| memoria canónica del corpus<br>aserciones reificadas | <b>SNOMED CT/UMLS (SCTID)</b><br>aserciones con <b>deóntica</b> ,<br>grado de evidencia y <b>vigencia</b> |
| enrutador de intención                               | router clínico (paciente,<br>numérica) + lente de umbrales                                                |
| pasaje propio                                        | sección normativa de la guía                                                                              |

**Estado actual (producción, congelada):**

- 8 guías; banco de 505 preguntas con validación clínica en curso;
- preguntas multi-guía (nivel 4): 84,9 % en el top-20 en modo grafo (denso: 24,7; BM25: 45,2) — el análogo clínico del multisalto;
- curación con humano en el bucle: bandeja de anclajes SNOMED auditable.



# GeSIDA de punta a punta: la metodología sobre un caso multi-guía



El multisalto clínico: la entidad canónica sct:DTG es el *punte* entre dos guías distintas — exactamente la estructura del puente de 2Wiki, con SNOMED en el papel de la memoria canónica. Contenido abreviado con fines ilustrativos; las aserciones reales llevan guía, sección, página y fecha de vigencia exactas.

# Qué aporta esta investigación a la clínica, y con qué salvaguardas

## Los tres portes con evidencia detrás:

1. **Cadena de evidencia multi-guía:** las preguntas nivel 4 son el análogo del puente; el gradiente invertido predice la mayor ganancia ahí.
2. **Abstención fundamentada:** los *huecos sin cubrir* del plan se convierten en *¿no hay evidencia sobre X en las guías?* — el fallo silencioso ( $FC = 0$  respondido de memoria) pasa a ser un aviso explícito y medible por pregunta.
3. **JSR clínico:** éxito = cadena normativa completa y respuesta correcta y vigencia comprobada — respuesta con expediente.

## Salvaguardas no negociables:

- Datos clínicos **nunca** a proveedores sin garantías (DeepSeek excluido del caso clínico); el diseño es agnóstico al modelo  $\Rightarrow$  proveedor UE o modelo local;
- validación *offline* contra el banco de 505 antes de tocar producción (sistema actual congelado y etiquetado);
- terminología curada (SNOMED) como fuente de verdad de identidad; el LLM propone, **nunca decide identidades**;
- trazabilidad completa: cada respuesta con su cadena, procedencia y vigencia.

# Conclusiones

1. Un grafo de **aserciones reificadas** sobre **entidades canónicas**, consultado con un **planificador de la evidencia**, recupera la cadena completa donde el estado del arte la rompe: 2Wiki FC@5 **97,7** frente a 65,8 (HippoRAG 2) y 67,6 (CatRAG), mismo backbone; HotpotQA **93,0** frente a 80,4 con cero ajuste.
2. La mejora está *atribuida*: representación (+12,7/+6,3 FC@5 frente al control sin grafo con idéntico presupuesto LLM) + planificador (repara las cadenas dobles: gradiente invertido) — y es *acumulación*, no colapso ( $FC \approx p^{|G_q|}$ ).
3. Todo con modelos pequeños e intercambiables ( $\sim 0,001$  \$/consulta), reproducible a coste cero, y con un camino directo a la clínica: mismas piezas con terminología curada, y la abstención fundamentada como dividendo de seguridad.

*Gracias — preguntas.*

código y artefactos: [github.com/bjur27r/hiv\\_rag](https://github.com/bjur27r/hiv_rag) (rama eval-wiki2)