

Recuperación multisalto sobre un grafo de aserciones reificadas con memoria canónica de entidades y planificación de la evidencia

Evaluación en benchmarks públicos y aplicación al asistente clínico sobre las guías de
GeSIDA

Septiembre de 2026

Guion

Introducción


Metodología

Resultados

Discusión

Aplicación: asistente clínico sobre las guías de GeSIDA

El problema: la pregunta no se parece a la evidencia que falta




- La recuperación densa/léxica encuentra lo *nombrado*, no lo *encadenado*: la información que identifica al pasaje puente solo aparece *tras leer* el primero.
- Consecuencia medible: exhaustividad parcial alta con **cadena rota** (BM25 en cadenas dobles: $R@5 = 50,9$ pero $FC@5 = 0,9$).

La métrica alineada con la tarea: cadena completa (FC@k)

Definiciones (pregunta q , oro G_q , top- k T_k)

$$R@k = \frac{|G_q \cap T_k|}{|G_q|} \quad FC@k = \mathbf{1}[G_q \subseteq T_k]$$




3 de 4 pasajes $\Rightarrow$ R@5 alta,
FC@5 = 0: **no hay respuesta fundamentada**

- Un lector no puede componer la respuesta si le falta *un* eslabón: R@5 = 0,75 en una cadena de 4 vale lo mismo que 0.
- FC@k (*Full Chain Retrieval*) es la métrica de integridad del razonamiento propuesta por CatRAG (Lau et al., ACL 2026).

Estado del arte: HippoRAG 2 (PPR sobre grafo de triplete; Gutiérrez et al. 2025) y CatRAG (recorrido adaptativo a la consulta). Sus dos límites estructurales: *identidad de entidades sin resolver* y *recursos fijos por consulta*.

Arquitectura: pagar una vez en indexación, decidir bien en consulta



- Modelos pequeños en todo: gpt-4o-mini / deepseek-chat + text-embedding-3-small (1536 d).
- En **naranja**, las tres decisiones LLM de la consulta (el *planificador*); el resto es álgebra y estructura.


Notación

símbolo	significado
q	pregunta; $e(\cdot) \in \mathbb{R}^{1536}$, $\ e(x)\ _2=1$
$\mathcal{D} = \{c_i\}$	corpus de pasajes; c un pasaje
$G_q / T_k(q)$	pasajes oro / los k primeros devueltos
$a; \tau_a$	aserción; su frase autocontenida
$\sigma_a = \langle e(q), e(\tau_a) \rangle$	afinidad pregunta–hecho
$S(q); \tilde{\sigma}_a$	hechos aprobados; afinidad corregida
$\varepsilon \in \mathcal{E}$	entidad canónica del diccionario
$L(q)$	entidades enlazadas desde la pregunta

símbolo	significado
$\mathcal{A}_\varepsilon; \pi(\varepsilon)$	alias de ε ; su pasaje propio
$\mathbf{v} \in \mathbb{R}^{ V }$	vector de personalización (siembra)
$\epsilon = 0,05$; $w_{\text{enl}}=0,5$	ancla débil; peso de enlace
$A; \mu_a; \tilde{A} = A \text{diag}(\mu)$	adyacencia; modulación por hecho
$P = D^{-1}\tilde{A}$; $\lambda = 0,5$	transición por filas; amortiguación
$\mathbf{p}^{(t)} \rightarrow \mathbf{p}^*$	masa del paseo; distribución final
$R@k$; $FC@k$	exhaustividad; cadena completa
p (modelo nulo)	fiabilidad por eslabón: $FC \approx p^{ G_q }$

Convención tipográfica: **naranja** = decisiones del modelo de lenguaje; **azul** = estructura y álgebra; **verde** = evidencia oro o flujo correcto; **rojo** = fallo o deriva.

El proceso completo de un vistazo: componentes en paralelo



Cada artefacto de indexación alimenta pasos concretos de la consulta (buses grises): los vectores a la afinidad ①, el diccionario al enlazador ② y a la siembra ④, las aserciones al analista ③ y el grafo al paseo ⑤–⑥.

Cada componente: entrada, salida y papel

componente	entrada	salida	papel en el sistema
extracción reificada	pasaje c	menciones E_C ; aserciones $A_C = \{(s, r, o, Q, \tau)\}$	convierte prosa en hechos direccionables con frase τ_a
diccionario (memoria canónica)	todas las menciones (c, f)	entidades $\mathcal{E}$ con alias $\mathcal{A}_\mathcal{E}$, ficha, $\pi(\varepsilon)$	resuelve la identidad en el índice: elimina las ñislasz
grafo canónico G	$A_C, \mathcal{E}$	nodos $\mathcal{C} \cup \mathcal{E} \cup \mathcal{A}$, aristas de rol/procedencia/mención	soporte del paseo: la masa puede cruzar los hechos
① afinidad	$e(q), \{e(\tau_a)\}$	σ_a para toda aserción	preselección global (un producto matricial)
② enlazador	menciones de q , alias	$L(q) \subseteq \mathcal{E}$	ancla la pregunta a nodos exactos; aporta la frontera
③ analista (LLM)	$q + \text{candidatos } \text{Top}_{40} \cup \text{frontera}$	plan (huecos), $S(q)$, huecos sin cubrir	decide <i>utilidad</i> , no semejanza; tope = n.º de huecos
④ siembra	$S(q), L(q), \pi(\cdot), e(c)$	$\mathbf{v}$ (puerta 1; +0,5 π ; suelo 0,05; ϵ)	concentra el reinicio en la cadena aprobada
⑤–⑥ PPR modulado	$A, \mu(\tilde{\sigma}), \mathbf{v}$	$\mathbf{p}^*$	difusión estructural con preferencia por hechos afines
⑦ salto dirigido (LLM)	huecos + hechos de $\pi(\varepsilon)$	nuevos aprobados $\rightarrow$ re-siembra	repara el eslabón ausente (alias en otro idioma)
⑧ conjunto final (LLM)	plan + top-12 de $\mathbf{p}^*$	5 pasajes que cubren el plan	optimiza F1@5 como propiedad del conjunto

Indexación y representación: del texto a la estructura


Tres transformaciones, cada una con su invariante:

1. **Reificación** ($c \mapsto A_c$): cada hecho atómico del pasaje se promueve a objeto con frase autocontenida τ_a , calificadores y procedencia.
Invariante: lo que la pregunta comparará (fechas, dosis) viaja dentro de la unidad recuperable.
2. **Canonicalización** (menciones $\mapsto \mathcal{E}$): fichas por mención, candidatos por nombre y por contexto, restricciones duras, adjudicación LLM. *Invariante*: una entidad real = un nodo, con sus alias y su pasaje propio $\pi(\varepsilon)$.
3. **Materialización** ($\mathcal{C}, \mathcal{E}, \mathcal{A} \mapsto G$): grafo tripartito sin aristas de sinonimia. *Invariante*: todo camino entidad $\rightarrow$ entidad pasa por un hecho explícito y ponderable.


Tamaños reales (2Wiki): 6 119 pasajes $\rightarrow$ 47 999 aserciones, 26 940 entidades, 165k aristas; coste $\approx$ 3 \$ y $\sim$ 40 min, una única vez.



Pieza 1 ð La unidad semántica: aserción reificada, no triplete



(a) HippoRAG 2: el hecho es una *arista* binaria, anónima, sin procedencia




(b) CatRAG-Reif: el hecho es un *nodo* con frase propia, roles *n*-arios y vector $e(\tau_a)$

- Se incrusta **la frase**, no la etiqueta: robusto a etiquetas ruidosas; las fechas viajan *dentro* del hecho.
- El paseo aleatorio **razona a través del hecho** (entidad $\rightarrow$ aserción $\rightarrow$ otra entidad / pasaje) y su tránsito se modula por la consulta: $\mu_a = \frac{1}{4} + \frac{3}{4} \tilde{\sigma}_a$.

Fundamento de la representación: tres propiedades de la aserción-nodo

1. **Modulabilidad por consulta.** En un grafo de tripletes, la distribución de transición desde una entidad queda fijada en indexación y es idéntica para toda consulta; CatRAG la re-pondera, pero sobre el mismo soporte binario. Con hechos-nodo, cada hecho es una unidad *direccionable*: $P(\varepsilon \rightarrow a) \propto \mu_a(q)$ con $\mu_a = \frac{1}{4} + \frac{3}{4} \tilde{\sigma}_a(q)$, y los hechos aprobados por el analista transitan a peso completo.
2. **Clausura n -aria.** El triplete (s, r, o) impone binariedad: participantes adicionales y calificadores (fechas, dosis) se pierden o generan nodos literales. La aserción los conserva en τ_a y en sus roles: *la unidad recuperada ya contiene el dato que la pregunta compara*.
3. **Semántica de la frase.** La afinidad se computa sobre $e(\tau_a)$ —una frase autocontenida— y no sobre la concatenación de etiquetas; el sistema es robusto al ruido de etiquetado del extractor.



consulta: *ñwho is older. . .* ð
grafo plano: 30 aristas **indistinguibles**;
reificado: la masa **se concen-**
tra en el hecho pertinente

Pieza 2 ù Memoria canónica de entidades: matar las ñislasž en el índice



entrada canónica can:h. p. lovecraft
alias: {H. P. Lovecraft; Howard Phillips Lovecraft}
descripción: ñAmerican writer of weird fiction...ž
pasaje propio: *H. P. Lovecraft*

fichas por mención (nombre + contexto) → candidatos por 2 canales → restricciones duras (fechas, ordinales) → adjudicación LLM → fusión; el título del artículo es alias del sujeto

- Construida **una vez, solo del corpus** (jamás del oro); auditable; con QIDs de Wikidata como verificación externa opcional (v4).
- Resultado: variantes de nombre colapsan en **un** nodo ⇒ el grafo canónico no necesita aristas de sinonimia; 178/188 islas resueltas en el sondeo.
- Es el análogo, derivado del corpus, del *linker* SNOMED del caso clínico.

Pieza 3 ù El analista: planificar la cadena antes de seleccionar

ñWhich film has the director died first, Bílá Spona or A Night at Earl Carroll's?ž

hechos candidatos (top-40 coseno $\cup$ frontera)
2: A Night at Earl Carroll's ... **directed by Kurt Neumann**
6: Bílá spona was ... **directed by Martin Frič**
8: *Earl Carroll* (el actor) *died on June 17, 1948* ...

plan (huecos):

director de Bílá spona → Martin Frič

fecha de muerte de Martin Frič

director de A Night... → Kurt Neumann

fecha de muerte de Kurt Neumann

Sin plan (selector directo, tope 4):

eligió al actor Earl Carroll como ñdirectorž

y omitió a Kurt Neumann *que estaba en la lista* ⇒ cadena rota.


Con plan (tope = n.ž de huecos):

selecciona los dos hechos puente; regla dura:

prohibido rellenar huecos con conocimiento propio del modelo ([X]).

La misma llamada hace de **enlazador** (menciones → forma canónica → diccionario) y declara los **huecos sin cubrir**, que alimentan el salto dirigido y, en clínica, la abstención fundamentada.

Pieza 4 ù Salto dirigido estructural: cuando el artículo habla en otro idioma



el coseno del hueco con ñIngmar Bergman directed *Ansiktet.z* es **bajo** (cero vocabulario común);
la ruta **estructural** (entidad enlazada → su pasaje propio → sus hechos, con procedencia visible)
lo rescata: el mini-filtro aprueba, Bergman se siembra, su biografía entra en el top-2

- Solo se ejecuta si el plan dejó huecos (~15–25 % de las consultas); una ronda.
- Es la capacidad nueva de verdad: resolver puentes **inmunes al alias** (idiomas, títulos originales), imposibles para similitud y sinonimia.

Piezas 5–6 ù Siembra con compuerta dura y PPR modulado; conjunto final


Vector de reinicio $\mathbf{v}$ (4 fuentes):

1. **compuerta dura**: solo siembran las entidades de hechos *aprobados* (peso 1); si nada aprueba $\rightarrow$ degradación suave al denso;
2. presa densa sobre *todos* los pasajes ($\times 0,05$);
3. anclas débiles ($\epsilon = 0,05$);
4. **pasaje propio**: $\mathbf{v}(\pi(\epsilon)) \leftarrow 0,5 \mathbf{v}(\epsilon)$ — *ñel artículo de una entidad es la entidadz.*

$$\mathbf{p}^{(t+1)} = \lambda \left(P^\top \mathbf{p}^{(t)} + m_{\text{colg}} \mathbf{v} \right) + (1 - \lambda) \mathbf{v}, \quad \lambda = 0,5$$

con P renormalizada tras modular las entradas a cada hecho por su afinidad ($\mu_a \in [\frac{1}{4}, 1]$; los aprobados a peso completo).


Conjunto final (salvo comparaciones simples):



FC@ k es una propiedad *del conjunto*, no de cada pasaje: esta decisión no la puede expresar un ranking punto a punto. Aporta +6 puntos de FC@2 (orden temprano).

El vector de personalización $\mathbf{v}$, con valores observados

Traza real: *¿Who is the mother of the director of film Atomised (Film)?* (oro: *Atomised (film)*, *Oskar Roehler*).




Composición de cada componente:

- can:atomised = 1,0 (compuerta) + 0,05 (ancla del enlazador);
- can:oskar roehler = 1,0: entidad del hecho aprobado —*descubierta*, no nombrada en la pregunta;
- los dos *pasajes propios* reciben $0,5 \cdot \mathbf{v}(\epsilon)$ más su presa densa;
- el resto del corpus conserva un suelo denso ($0,05 \cdot$ similitud).

Tras el paseo: $p^*(\text{Atomised}) = 0,0084$,
 $p^*(\text{Roehler}) = 0,0063$, primer distractor
0,0004 (un orden de magnitud): FC@2 = 1.

El algoritmo de consulta, paso a paso sobre el grafo

1. $v_0 = e(q)$; afinidad $\sigma_a = \langle v_0, e(\tau_a) \rangle$ para las 47 999 aserciones (un producto matricial).
2. Enlazador: menciones $\rightarrow$ diccionario $\rightarrow L(q) \subseteq \mathcal{E}$.
3. **Analista** sobre $\text{Top}_{40}\{\sigma\} \cup$ frontera de $L(q)$: plan, selección $S(q)$, huecos.
4. Siembra de $\mathbf{v}$ sobre nodos del grafo: entidades de $S(q)$ a peso 1; +0,5 a sus pasajes propios; suelo denso en todo pasaje; anclas ϵ .
5. Modulación: $\tilde{A} = A \text{diag}(\mu)$, $P = D^{-1} \tilde{A}$ (renormalización por filas).
6. Paseo: $\mathbf{p}^{(t+1)} = \lambda(P^\top \mathbf{p}^{(t)} + m_{\text{colg}} \mathbf{v}) + (1 - \lambda) \mathbf{v}$ hasta $\|\Delta \mathbf{p}\|_1 < 10^{-9}$.
7. Si quedan huecos: **salto dirigido** (hechos del pasaje propio de la entidad del hueco $\cup$ coseno del hueco) $\rightarrow$ re-siembra $\rightarrow$ una re-iteración del paseo.
8. Restricción de $\mathbf{p}^*$ a pasajes; **conjunto final** de 5 que cubre el plan.




Arquitectura agéntica completa: de la pregunta a la respuesta

Censo de papeles LLM del sistema, por fase y cadencia:

- **Indexación** (una vez por corpus, fuera de línea): *extractor* ($c \mapsto E_c, A_c$) y *adjudicador* ($\mathbb{E}$ misma entidad? sobre pares ambiguos del diccionario).
- **Recuperación** (por consulta, lo evaluado): *analista* (plan + selección; siempre), *reparador* (huecos; $\sim 20\%$), *empaquetador* (conjunto de 5; salvo comparación).
- **Respuesta** (por consulta): *lector* (compone la respuesta desde el top-5, con citas) y, en el caso clínico, *verificador* (deóntica, umbrales numéricos, vigencia). En los benchmarks: evaluación EM/F1+JSR planificada.

Guardarraíles comunes: contratos JSON validados; presupuesto ≤ 3 llamadas en recuperación; degradación suave a denso; caché por (modelo, consigna); los roles *leen* las herramientas, nunca las escriben —la memoria solo cambia en indexación. *El LLM decide dentro de contratos; el algoritmo conserva el control* (sin bucle libre tipo IRCot: latencia y coste acotados por diseño).



abstención si
hueco sin cub

Conjuntos de datos (subconjuntos de reproducción publicados con HippoRAG 2):

dataset	origen	preguntas	pasajes	estructura de la evidencia
2WikiMultihopQA	Ho et al. 2020 (Wikipedia+Wikidata)	1 000	6 119	2–4 oros; 4 tipos etiquetados
HotpotQA	Yang et al. 2018 (Wikipedia)	1 000	9 811	2 oros; <i>bridge</i> / <i>comparison</i>

Modelos (paridad estricta entre sistemas):


papel	modelo	dimensión / tamaño	uso
codificador vectorial	text-embedding-3-small	1536 d	todos los sistemas y espacios
extracción e índice	gpt-4o-mini	—	aserciones, diccionario (lotes, caché)
planificador (consulta)	deepseek-chat (V3)	—	configuración adoptada
alternativas validadas	gpt-oss-20b (Groq) / gpt-4o-mini	20 B / —	97,0 / 96,0 FC@5 en sondeo

Sistemas de referencia: HippoRAG 2 ejecutado con su código oficial y los mismos modelos (reproducción validada al decimal); CatRAG por sus cifras publicadas con este mismo backbone (código no liberado); BM25 propio.

Infraestructura: CPU de sobremesa (sin GPU); cachés persistentes (SQLite/npz) para toda llamada y vector; coste total del estudio $\approx 40 \$$; cualquier medición es re-ejecutable de forma determinista a coste cero. Código y artefactos: github.com/bjur27r/hiv_rag.

Protocolo experimental: paridad estricta y separación de datos


- **Datasets** (subconjuntos de reproducción de HippoRAG 2/CatRAG): 2WikiMultihopQA (1000 preguntas $\times$ 6119 pasajes) y HotpotQA (1000 $\times$ 9811); recuperación *abierta* contra el corpus completo.
- **Paridad**: HippoRAG 2 ejecutado con *su propio código* y los *mismos modelos*; CatRAG publica con este mismo backbone (gpt-4o-mini+te3-small) $\Rightarrow$ comparación directa legítima.
- **Validación cruzada de la reproducción**: nuestro HippoRAG 2 en 2Wiki (85,9/65,8) coincide **al decimal** con la reproducción independiente del artículo de CatRAG (85,9/66,1).
- **Estadística**: pareado por pregunta, bootstrap $B=2000$, IC 95 %.



Configuración **congelada** antes de medir; en HotpotQA, *cero ajuste* al conjunto.

2WikiMultihopQA: resultado principal (todos con el mismo backbone)

	R@2	R@5	FC@5	FC@10
BM25	—	65,8	32,8	40,1
HippoRAG 2 (su código)	70,7	85,9	65,8	71,7
CatRAG (publicado; código no liberado)	—	87,0	67,6	—
CATRAG-REIF v3 (diccionario)	73,0	96,0	90,6	93,4
CatRAG-Reif v4 + planificador (gpt-4o-mini)	80,2	98,1	96,0	96,7
CatRAG-Reif v4 + planificador (deepseek-chat)	84,2	98,9	97,7	97,8



Pareado v4–HippoRAG 2: $\Delta FC@5 = +31,9$ [+28,9, +34,9] (gana 326 / pierde 7); todos los tipos significativos. El artículo de HippoRAG 2 con NV-Embed-v2 (7 B, GPU) reporta $R@5 = 90,4$; aquí 98,9 con modelos de una fracción de ese coste.

Estudio de caso: tres mecanismos de recuperación ante la misma consulta

¿Which film has the director who is older, God's Gift to Women or Aldri annet enn bråk?ž — oro: 2 filmes + sus directores (M. Curtiz, E. Carlmar).

HippoRAG 2 (medido)

siembra = frases de los triples filtrados:
{Aldri..., God's Gift..., E. Carlmar}

paseo con T estática: la masa difunde por el vecindario más denso — las *otras películas* de Carlmar

Curtiz no se siembra nunca: el filtro (≤ 4 triples) cubrió una sola rama y T no depende de q

top-5: 3 oros + 2 filmes de Carlmar
R@5=0,75; FC@5=0

CatRAG (su mecanismo)

misma siembra y mismo grafo de tripletes que HippoRAG 2

re-pondera las aristas próximas a las semillas según q (anclas ϵ , pesos por LLM)

no puede crear la semilla ausente ni fusionar identidades: hereda el modo de fallo

publicado (2Wiki, mismo backbone):
FCR = 67,6
(+1,5 sobre su base)

CatRAG-Reif (medido)

plan: director de $A \rightarrow [X]$; director de $B \rightarrow [X]$; fechas de ambos $\Rightarrow$ aprueba *los dos* hechos DIRECTED


compuerta: $v=1$ en can:curtiz y can:carlmar ; +0,5 a *sus pasajes propios*

paseo con $\mu=1$ en ambos hechos; el **conjunto** exige cubrir los 4 huecos

top-4 = los 4 oros
R@5=1; FC@5=1

La diferencia es de *mecanismo*, no de grado: los recursos de HippoRAG 2/CatRAG se fijan **por consulta** (una siembra, un grafo, una T); los nuestros se asignan **por hueco del plan** — por eso la segunda cadena existe para el sistema antes de empezar a caminar.

El hallazgo central: acumulación frente a colapso con la profundidad



Modelo nulo: eslabones independientes


$$\Rightarrow FC \approx p^{|G_q|}$$

	C predicho	C obs.	razón
HippoRAG 2	59,2	12,3	0,21
CATRAG-REIF	80,3	83,8	1,04

CATRAG-REIF degrada por *acumulación* de $\sim 5\%$ de error por eslabón. HippoRAG 2 *colapsa*: sus recursos por consulta (selección ≤ 4 , masa, holgura del top-5) son fijos y compartidos entre las dos cadenas. El planificador invierte el gradiente: con v4, la cadena doble alcanza $FC@5 = 98,7$ — el segmento históricamente peor pasa a ser el mejor.

Atribución: ablaciones y control sin grafo

Escalera de contribuciones (sondeo):



El plan por sí solo apenas mueve (+0,5): su valor es *habilitar* al salto (+3,0; cadena doble 86 → 96) y al conjunto (+1,5; +6 FC@2).

¿Grafo o planificador? Control *sin grafo* con idéntico presupuesto LLM (mismo analista/salto/conjunto sobre top-20 denso):

banco	v4	control	Δ [IC 95 %]
2Wiki	96,0	83,3	+12,7 [+10,5, +14,9]
HotpotQA	90,2	83,9	+6,3 [+4,1, +8,6]

Criterio pre-registrado (≥ 5 y sig. en ambos): **cumplido**
⇒ la **representación** aporta más allá del planificador. El planificador solo repara cadenas dobles; el puente simple lo repara el grafo (oro perdido por el control: 130/141 ni siquiera en su top-20).

Generalización sin ajuste y robustez al modelo

HotpotQA ($1\,000 \times 9\,811$), configuración congelada de 2Wiki:

	R@5	FC@5
BM25 (nuestro)	72,8	49,5
denso te3-small (pub.)	81,3	64,9
HippoRAG 2 (publicado)	87,1	75,5
CatRAG (publicado)	89,5	80,4
CatRAG-Reif v4 (4o-mini)	94,7	90,2
CatRAG-Reif v4 (deepseek)	96,0	93,0

+6,5 R@5 / +12,6 FC@5 sobre CatRAG con *cero* ajuste al conjunto.

El modelo del planificador es intercambiable (sondeo 2Wiki, FC@5):

modelo	FC@5	\$/consulta
deepseek-chat	97,5	0,0010
groq gpt-oss-20b	97,0	0,0005
gpt-4o	96,5	0,012
gpt-4o-mini	96,0	0,0008

La ganancia es del *diseño de la tarea*, no del tamaño: un 20 B abierto casi empata con gpt-4o a 1/24 del coste. Estudio completo: ~40 \$; toda llamada cacheada (reproducción a coste cero).

Discusión: por qué funciona y qué falta

Tres principios, cada uno elimina una dependencia de la profundidad:

1. **Identidad en el índice** (memoria canónica): las *nislasz* no se multiplican con los saltos; la sinonimia por umbral sí.
2. **Hechos como nodos de primera clase**: la masa viaja *a través* del hecho aprobado; los calificadores viajan con él.
3. **Recursos que escalan con la cadena** (plan, salto, conjunto): el presupuesto se asigna por hueco, no por consulta — de ahí la inversión del gradiente en cadenas dobles.

Validez: reproducción del baseline verificada al decimal contra una reproducción independiente; diseño íntegro en conjuntos retenidos; una medición por configuración; artefactos y cachés públicos (reproducible a coste cero).

Límites y trabajo en curso: QA extremo a extremo (EM/F1, JSR) pendiente; MuSiQue (saltos 2/3/4 etiquetados: contraste directo del modelo multiplicativo); inferencia con $n=108$ no alcanza significación aislada; heurísticas léxicas residuales sustituidas por el analista, pendiente de medir en otros idiomas.


El caso de uso origen: asistente sobre 8 guías clínicas de GeSIDA

La arquitectura no nació en Wikipedia: es la generalización del asistente clínico VIH **ya construido**, donde cada pieza tiene su análogo curado:


benchmark	clínica (GeSIDA)
memoria canónica del corpus aserciones reificadas	SNOMED CT/UMLS (SCTID) aserciones con deóntica , grado de evidencia y vigencia
enrutador de intención	router clínico (paciente, numérica) + lente de umbrales
pasaje propio	sección normativa de la guía

Estado actual (producción, congelada):

- 8 guías; banco de 505 preguntas con validación clínica en curso;
- preguntas multi-guía (nivel 4): 84,9 % en el top-20 en modo grafo (denso: 24,7; BM25: 45,2) — el análogo clínico del multisalto;
- curación con humano en el bucle: bandeja de anclajes SNOMED auditable.



GeSIDA de punta a punta: la metodología sobre un caso multi-guía



El multisalto clínico: la entidad canónica sct:DTG es el *punte* entre dos guías distintas — exactamente la estructura del puente de 2Wiki, con SNOMED en el papel de la memoria canónica. Contenido abreviado con fines ilustrativos; las aserciones reales llevan guía, sección, página y fecha de vigencia exactas.

Qué aporta esta investigación a la clínica, y con qué salvaguardas

Los tres portes con evidencia detrás:

1. **Cadena de evidencia multi-guía:** las preguntas nivel 4 son el análogo del puente; el gradiente invertido predice la mayor ganancia ahí.
2. **Abstención fundamentada:** los *huecos sin cubrir* del plan se convierten en *¿no hay evidencia sobre X en las guías?* — el fallo silencioso ($FC = 0$ respondido de memoria) pasa a ser un aviso explícito y medible por pregunta.
3. **JSR clínico:** éxito = cadena normativa completa y respuesta correcta y vigencia comprobada — respuesta con expediente.

Salvaguardas no negociables:

- Datos clínicos **nunca** a proveedores sin garantías (DeepSeek excluido del caso clínico); el diseño es agnóstico al modelo $\Rightarrow$ proveedor UE o modelo local;
- validación *offline* contra el banco de 505 antes de tocar producción (sistema actual congelado y etiquetado);
- terminología curada (SNOMED) como fuente de verdad de identidad; el LLM propone, **nunca decide identidades**;
- trazabilidad completa: cada respuesta con su cadena, procedencia y vigencia.

Conclusiones

1. Un grafo de **aserciones reificadas** sobre **entidades canónicas**, consultado con un **planificador de la evidencia**, recupera la cadena completa donde el estado del arte la rompe: 2Wiki FC@5 **97,7** frente a 65,8 (HippoRAG 2) y 67,6 (CatRAG), mismo backbone; HotpotQA **93,0** frente a 80,4 con cero ajuste.
2. La mejora está *atribuida*: representación (+12,7/+6,3 FC@5 frente al control sin grafo con idéntico presupuesto LLM) + planificador (repara las cadenas dobles: gradiente invertido) — y es *acumulación*, no colapso ($FC \approx p^{|G_q|}$).
3. Todo con modelos pequeños e intercambiables ($\sim 0,001$ \$/consulta), reproducible a coste cero, y con un camino directo a la clínica: mismas piezas con terminología curada, y la abstención fundamentada como dividendo de seguridad.

Gracias — preguntas.

código y artefactos: github.com/bjur27r/hiv_rag (rama eval-wiki2)